

Basic Neural Radiance Fields (NeRF)

This notebook implements a basic **Neural Radiance Field** (NeRF) from scratch using PyTorch.

The Paper: "NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis"

- **Original Paper:** [Mildenhall et al. ECCV 2020](#)
- **Core Concept:** A scene is represented as a continuous 5D function $F(x, y, z, \theta, \phi) \rightarrow (r, g, b, \sigma)$, parameterized by a fully connected deep network (MLP).

1. The 5D Coordinate Representation

A NeRF takes a **continuous 5D coordinate** as input:

- **Spatial Location:** $\mathbf{x} = (x, y, z)$
- **Viewing Direction:** $\mathbf{d} = (\theta, \phi)$

The output is:

- **Volume Density** $\sigma(\mathbf{x})$: Represents the probability of a ray terminating at location $\mathbf{x}$. Crucially, density is predicted **independent** of the viewing direction (geometry is the same regardless of where you look from).
- **Color** $\mathbf{c}(\mathbf{x}, \mathbf{d}) = (r, g, b)$: The emitted radiance. Color **depends** on the viewing direction, allowing the model to represent view-dependent effects like specular reflections.

2. Network Architecture

The MLP F_{θ} is structured to enforce multiview consistency:

1. **Input:** 3D position $\mathbf{x}$ (with Positional Encoding).
2. **Density Network:** Passes through 8 fully-connected layers (ReLU activations, 256 channels). Outputs σ and a feature vector.
3. **View Injection:** The feature vector is concatenated with the viewing direction $\mathbf{d}$ (Positional Encoded).
4. **Color Network:** Processes the concatenated vector to output RGB color.

This structure ensures that the geometry (σ) is consistent across all views, while color can vary effectively.

3. Volume Rendering Equation

To render a pixel, we shoot a ray $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ into the scene and integrate the color along it: $C(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt$ where $T(t) = \exp(-\int_{t_n}^t \sigma(\mathbf{r}(s)) ds)$ is the accumulated transmittance (probability that the ray travels from t_n to t without hitting anything).

4. Positional Encoding

Deep networks are biased towards learning low-frequency functions (Spectral Bias). To capture high-frequency details (sharp edges, textures), inputs (x, y, z) are mapped to a higher dimensional space using sinusoidal functions: $\gamma(p) = (\sin(2^0\pi p), \cos(2^0\pi p), \dots, \sin(2^{L-1}\pi p), \cos(2^{L-1}\pi p))$

Comparison with Other Techniques

NeRF vs. 3D Gaussian Splatting (3DGS)

- **Representation:** NeRF is **Implicit** (a neural network defines the scene). 3DGS is **Explicit** (millions of discrete Gaussian blobs).
- **Rendering Speed:** NeRF requires querying a huge MLP hundreds of times *per pixel*, making it slow (seconds/minutes per frame). 3DGS projects Gaussians via rasterization, running in **real-time** (30-100+ FPS).
- **Training Speed:** NeRF takes hours/days. 3DGS takes minutes/hours.
- **Quality:** NeRF has less artifacts but can be blurry. 3DGS is sharper but can have "popping" artifacts.

NeRF vs. Ray Tracing

- **Paradigm:** Ray Tracing simulates the physical transport of light (bounces, refraction, reflection) to generate an image from geometry. NeRF approximates the *radiance* field directly.
- **Usage:** Ray Tracing is "Forward Rendering" (Geometry $\rightarrow$ Image). NeRF is typically used for "Inverse Rendering" (Images $\rightarrow$ Geometry). Basic NeRF does not easily support relighting or moving objects, unlike Ray Tracing.

NeRF vs. Rasterization (Standard 3D)

- **Geometry:** Rasterization projects triangles (meshes) onto a 2D screen. NeRF integrates density along a ray.
- **Differentiability:** Rasterization is hard to differentiate because occlusion (edges) is discontinuous. NeRF's volumetric rendering is smooth and fully differentiable,

making it ideal for learning 3D structure from images.

NeRF vs. Precomputed Radiance Transfer (PRT)

- **Goal:** PRT solves the rendering equation for static scenes to enable fast real-time relighting with environment maps (using Spherical Harmonics).
- **Relighting:** PRT separates lighting from transfer functions. Basic NeRF "bakes" the lighting into the radiance field. To achieve PRT-like results, extensions like NeRF-W or Relighting NeRFs disentangle material (BRDF) from illumination.


Beginner Roadmap (No Graphics/NN Background Required)

This notebook teaches a minimal **Neural Radiance Field (NeRF)** by fitting a red sphere image.

- A **ray** is a line from the camera through one pixel.
- Along each ray, we sample many 3D points.
- A small neural network predicts color and density at each sample point.
- A differentiable renderer blends those predictions into a pixel color.
- Gradient descent updates network weights to match target pixels.

Diagram 1: End-to-End Workflow

Diagram 2: What Happens on One Ray



At each $x_i = o + t_i * d$:

`network(xi) -> (RGBi, sigmai)`

Renderer converts all samples into one pixel using:

```
alpha_i = 1 - exp(-sigma_i * delta_i)
weight_i = alpha_i * product_{j<i} (1 - alpha_j)
pixel_color = sum_i(weight_i * RGB_i)
```

Why This First Code Cell Exists

It prepares the runtime: imports, device selection, and deterministic randomness. Without this setup, later training behavior can vary between runs and hardware.

```
In [1]: # Import PyTorch for tensors, GPU support, and automatic differentiation.
import torch
# Import the neural network module namespace (layers, containers, etc.).
import torch.nn as nn
# Import neural-network helper functions like ReLU and Softplus.
import torch.nn.functional as F
# Import NumPy for random index sampling and numeric utilities.
import numpy as np
# Import Matplotlib for plotting images and training curves.
import matplotlib.pyplot as plt

# Choose CUDA GPU if available, otherwise use CPU.
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
# Print the selected compute device so we know where tensors are running.
print(f"Using device: {device}")

# Fix PyTorch random seed for reproducible model initialization and sampling
torch.manual_seed(42)
# Fix NumPy random seed for reproducible batch index sampling.
np.random.seed(42)
```

Using device: cpu

1. Scene & Data Generation

We create a synthetic scene composed of simple geometric objects (Spheres) to train our NeRF on. Since we don't have an external dataset, we generate "Ground Truth" images by ray-tracing these spheres analytically.

```
In [2]: # Convert image pixels into 3D rays in world coordinates.
def get_rays(H, W, focal, c2w):
    # Create pixel x-coordinates from 0 to W-1 and y-coordinates from 0 to H-1.
    i, j = torch.meshgrid(torch.linspace(0, W - 1, W), torch.linspace(0, H - 1, H))
    # Transpose so i, j align with image row/column convention [H, W].
    i = i.t()
    # Transpose y-grid to match i tensor shape and orientation.
    j = j.t()

    # Convert pixels into camera-frame ray directions using pinhole camera geometry.
    dirs = torch.stack([(i - W * 0.5) / focal, -(j - H * 0.5) / focal, -torch.ones_like(i)])

    # Rotate camera-frame directions into world-frame directions using c2w rotation.
    rays_d = torch.sum(dirs[...], np.newaxis, :) * c2w[:3, :3], -1)

    # Copy camera position as the origin for every ray in the image.
    rays_o = c2w[:3, -1].expand(rays_d.shape)

    # Return per-pixel ray origins and directions.
    return rays_o, rays_d
```

```

# Render a synthetic sphere analytically to create ground-truth supervision.
def render_sphere_gt(H, W, focal, c2w, radius=0.5, center=torch.tensor([0, 0, 0, 1])):
    # Build one ray per pixel for this camera view.
    rays_o, rays_d = get_rays(H, W, focal, c2w)

    # Move rays into sphere-centered coordinates:  $oc = o - c$ .
    oc = rays_o - center
    # Quadratic coefficient a for ray-sphere intersection.
    a = torch.sum(rays_d ** 2, dim=-1)
    # Quadratic coefficient b for ray-sphere intersection.
    b = 2.0 * torch.sum(oc * rays_d, dim=-1)
    # Quadratic coefficient c for ray-sphere intersection.
    c = torch.sum(oc ** 2, dim=-1) - radius ** 2

    # Compute discriminant to test whether each ray hits the sphere.
    discriminant = b ** 2 - 4 * a * c
    # Keep only rays with positive discriminant (two real intersections).
    mask = discriminant > 0

    # Initialize output image to black RGB values.
    img = torch.zeros((H, W, 3))

    # Continue only if at least one ray intersects the sphere.
    if mask.any():
        # Choose nearest hit t (front surface) from quadratic formula.
        t = (-b[mask] - torch.sqrt(discriminant[mask])) / (2 * a[mask])
        # Compute 3D hit point coordinates for all intersecting rays.
        hit_points = rays_o[mask] + t.unsqueeze(-1) * rays_d[mask]

        # Compute outward unit normal at each surface hit point.
        normals = (hit_points - center) / radius
        # Define a fixed normalized directional light vector.
        light_dir = torch.tensor([0.577, 0.577, 0.577])

        # Lambertian diffuse shading =  $\max(0, \text{dot}(\text{normal}, \text{light}))$ .
        diffuse = torch.clamp(torch.sum(normals * light_dir, dim=-1), 0.0, 1.0)
        # Define constant base object color as red.
        col = torch.tensor([1.0, 0.0, 0.0])

        # Write shaded color plus small ambient term into hit pixels.
        img[mask] = col * diffuse.unsqueeze(-1) + 0.1

    # Return synthetic RGB target image.
    return img


# Set test image height and width in pixels.
test_H, test_W = 100, 100
# Set focal length in pixel units for a simple pinhole camera.
test_focal = 100
# Use identity camera-to-world transform (camera at origin, no rotation).
test_c2w = torch.eye(4)
# Render one synthetic ground-truth image of the sphere.
test_gt = render_sphere_gt(test_H, test_W, test_focal, test_c2w)

# Show the generated supervision image.
plt.imshow(test_gt)

```

```
# Add title describing what is displayed.
plt.title("Synthetic Ground Truth (Sphere)")
# Render the plot window/output cell figure.
plt.show()
```

Clipping input data to the valid range for imshow with RGB data ([0..1] for floats or [0..255] for integers). Got range [0.0..1.0992501].



2. NeRF Architecture

The model consists of:

1. **Positional Encoding:** $\gamma(p) = (\sin(2^0 \pi p), \cos(2^0 \pi p), \dots, \sin(2^{L-1} \pi p), \cos(2^{L-1} \pi p))$. This maps low-freq positions to high-freq features, enabling the network to learn fine details (spectral bias).
2. **MLP:** A simple fully connected network.

Diagram 2A: MLP Inside NeRF (Mermaid Render)\n

```
In [ ]: %%html
<div class="mermaid">
flowchart LR
    A[3D point x,y,z] --> B[Positional Encoding]
    B --> C[Encoded vector]
    C --> L1[Linear plus ReLU Layer 1]
    L1 --> L2[Linear plus ReLU Layer 2]
    L2 --> L3[Linear plus ReLU Layer 3]
```

```

L3 --> L4[Linear plus ReLU Layer 4]
L4 --> S[Skip Connection concat original encoded input]
C --> S
S --> L5[Linear plus ReLU Layer 5]
L5 --> L6[Linear plus ReLU Layer 6]
L6 --> L7[Linear plus ReLU Layer 7]
L7 --> L8[Linear plus ReLU Layer 8]
L8 --> O[Output Linear]
O --> R[RGB r g b]
O --> D[Sigma density]
</div>

<script src="https://cdn.jsdelivr.net/npm/mermaid@10/dist/mermaid.min.js"></script>
mermaid.initialize({ startOnLoad: true, securityLevel: 'loose' });
mermaid.run({ querySelector: '.mermaid' });
</script>

```

```

In [3]: # Define positional encoding to map low-frequency coordinates to richer features
class PositionalEncoding(nn.Module):
    # Construct encoding module with number of frequency bands L_embed.
    def __init__(self, L_embed=6):
        # Initialize parent PyTorch module internals.
        super().__init__()
        # Store number of sinusoidal frequency levels.
        self.L_embed = L_embed

    # Forward pass: encode input 3D points x into higher-dimensional representations
    def forward(self, x):
        # Start embedding list with original coordinates (identity term).
        emb = [x]
        # For each frequency scale 2^i, append sin and cos projections.
        for i in range(self.L_embed):
            # Append sine features for current frequency band.
            emb.append(torch.sin(2.0 ** i * x))
            # Append cosine features for current frequency band.
            emb.append(torch.cos(2.0 ** i * x))
        # Concatenate all features along last dimension.
        return torch.cat(emb, dim=-1)

# Define a minimal NeRF-style MLP that predicts RGB and density per 3D point
class NeRF(nn.Module):
    # Build model with depth D, width W, output channels, skip layers, and positional encoding
    def __init__(self, D=8, W=256, output_ch=4, skips=[4], L_embed=6):
        # Initialize parent PyTorch module internals.
        super().__init__()
        # Save skip-connection layer indices.
        self.skips = skips
        # Compute encoded input dimension: xyz + sin/cos bands for each xyz
        input_ch = 3 + 3 * 2 * L_embed

        # Build list of fully connected layers with optional skip input concatenation
        self.pts_linears = nn.ModuleList(
            [nn.Linear(input_ch, W)] +
            [nn.Linear(W, W) if i not in skips else nn.Linear(W + input_ch, W)
             for i in range(D - 1)]
        )

```

```

# Final linear layer outputs 4 values: RGB(3) and sigma density(1).
self.output_linear = nn.Linear(W, output_ch)

# Forward pass through MLP for encoded point features x.
def forward(self, x):
    # Initialize hidden activations with encoded input.
    h = x
    # Iterate over each hidden linear layer.
    for i, l in enumerate(self.pts_linears):
        # Apply current linear transformation.
        h = self.pts_linears[i](h)
        # Apply ReLU nonlinearity to hidden activations.
        h = F.relu(h)
        # If this layer is marked as skip, concatenate original input fe
    if i in self.skips:
        # Concatenate along feature dimension to preserve high-frequ
        h = torch.cat([x, h], -1)

    # Map final hidden state to raw RGB+sigma outputs.
    outputs = self.output_linear(h)
    # Return raw network predictions before rendering conversion.
    return outputs

```

3. Differentiable Volumetric Rendering

This is the core physics simulation. We sample points along the ray, query the model, and integrate. $C = \sum T_i \alpha_i c_i$ where $\alpha_i = 1 - \exp(-\sigma_i \Delta_i)$.

```

In [4]: # Convert raw NeRF predictions into rendered color/depth via volume rendering
def raw2outputs(raw, z_vals, rays_d):
    # Compute distances between consecutive sample depths along each ray.
    dists = z_vals[..., 1:] - z_vals[..., :-1]
    # Create a very large final distance so last sample can absorb remaining
    last_dist = torch.tensor([1e10], device=raw.device).expand(dists[..., :1])
    # Append final distance to maintain same sample count as raw predictions
    dists = torch.cat([dists, last_dist], -1)

    # Scale by ray direction norm to convert depth deltas into metric distances
    dists = dists * torch.norm(rays_d[..., None, :], dim=-1)

    # Convert first 3 raw channels into [0,1] RGB with sigmoid.
    rgb = torch.sigmoid(raw[..., :3])
    # Keep optional density noise term (set to zero in this simple notebook)
    noise = 0.0
    # Convert raw density channel into strictly positive sigma with Softplus
    sigma_a = F.softplus(raw[..., 3] + noise)

    # Compute per-sample alpha = probability of terminating at sample i.
    alpha = 1.0 - torch.exp(-sigma_a * dists)

    # Prepend transmittance seed value 1 and accumulate visibility along each

```



```

trans = torch.cumprod(
    torch.cat([torch.ones((alpha.shape[0], 1), device=alpha.device), 1.0
               -1,
               )[:, :-1]
    # Compute final contribution weights = alpha_i * transmittance_i.
    weights = alpha * trans

    # Render RGB as weighted sum of all sample colors on each ray.
    rgb_map = torch.sum(weights[..., None] * rgb, -2)
    # Render expected depth as weighted sum of sampled depths.
    depth_map = torch.sum(weights * z_vals, -1)

    # Return rendered color, depth, and per-sample weights.
    return rgb_map, depth_map, weights

# Render a batch of rays by sampling points, querying NeRF, and compositing
def render_rays(rays_o, rays_d, model, embedder, near=2.0, far=6.0, N_sample
    # Read compute device from incoming ray tensors.
    device = rays_o.device

    # Uniformly sample N depth values between near and far planes for each r
    z_vals = torch.linspace(near, far, N_samples, device=device).expand(rays

    # Compute midpoints of depth bins for stratified random perturbation.
    mids = 0.5 * (z_vals[..., 1:] + z_vals[..., :-1])
    # Build upper bounds for each bin.
    upper = torch.cat([mids, z_vals[..., -1:]], -1)
    # Build lower bounds for each bin.
    lower = torch.cat([z_vals[..., :1], mids], -1)
    # Draw random offsets in [0,1] for stochastic sampling per bin.
    t_rand = torch.rand(z_vals.shape, device=device)
    # Jitter samples inside each bin to reduce aliasing and improve training
    z_vals = lower + (upper - lower) * t_rand

    # Compute 3D sample points from ray equation  $x(t) = o + t*d$ .
    pts = rays_o[..., None, :] + rays_d[..., None, :] * z_vals[..., :, None]

    # Flatten points so MLP can process all samples as one batch.
    flat_pts = pts.reshape(-1, 3)
    # Apply positional encoding before passing into NeRF MLP.
    embedded_pts = embedder(flat_pts)

    # Predict raw RGB+sigma for all sampled points.
    raw = model(embedded_pts)
    # Reshape predictions back to [N_rays, N_samples, 4].
    raw = raw.reshape(rays_o.shape[0], N_samples, 4)

    # Perform differentiable volume rendering to obtain final ray outputs.
    rgb_map, depth_map, weights = raw2outputs(raw, z_vals, rays_d)

    # Return color and depth per ray.
    return rgb_map, depth_map

```

4. Training Loop

1. **Data:** Generate random rays from our view.
2. **Forward:** Render rays using NeRF.
3. **Loss:** MSE between Render and Ground Truth ($L = \|C - C_{\text{gt}}\|^2$).
4. **Backend:** Adam Optimizer.

Diagram 3: Training Loop Logic

```
In [5]: # Set number of positional encoding frequency bands.
L_embed = 6
# Create positional encoder module and move it to selected device.
embedder = PositionalEncoding(L_embed=L_embed).to(device)
# Create NeRF model and move it to selected device.
model = NeRF(L_embed=L_embed).to(device)
# Create Adam optimizer to update model parameters.
optimizer = torch.optim.Adam(model.parameters(), lr=5e-4)

# Define total number of training iterations.
N_iters = 1001
# Define number of random rays used per optimization step.
batch_size = 1024
# Define how often to print progress.
print_every = 100

# Create list to store scalar loss values over time.
history_loss = []

# Generate full ray set for the test image once (used for batching and final
test_rays_o, test_rays_d = get_rays(test_H, test_W, test_focal, test_c2w)
# Flatten ray origins from image grid [H,W,3] to list [H*W,3].
test_rays_o = test_rays_o.reshape(-1, 3).to(device)
# Flatten ray directions from image grid [H,W,3] to list [H*W,3].
test_rays_d = test_rays_d.reshape(-1, 3).to(device)
# Flatten target image RGB from [H,W,3] to [H*W,3].
test_target = test_gt.reshape(-1, 3).to(device)

# Print training start message.
print("Starting Training...")

# Run gradient-based optimization loop.
for i in range(N_iters):
    # Set model to training mode.
    model.train()

    # Randomly choose ray indices for this minibatch (single-view overfit de
    idxs = np.random.choice(test_rays_o.shape[0], batch_size, replace=False)
    # Gather minibatch ray origins using sampled indices.
    batch_rays_o = test_rays_o[idxs]
    # Gather minibatch ray directions using sampled indices.
    batch_rays_d = test_rays_d[idxs]
    # Gather minibatch target RGB values using sampled indices.
    batch_target = test_target[idxs]

    # Render predicted RGB and depth for selected rays.
```

```

rgb, depth = render_rays(batch_rays_o, batch_rays_d, model, embedder, ne

# Compute mean squared error between predicted and target RGB.
loss = torch.mean((rgb - batch_target) ** 2)

# Clear old gradients before backpropagation.
optimizer.zero_grad()
# Backpropagate loss to compute gradients of all trainable parameters.
loss.backward()
# Apply one optimizer update step.
optimizer.step()

# Save scalar loss value for later plotting.
history_loss.append(loss.item())

# Periodically print training progress.
if i % print_every == 0:
    # Show current iteration number and loss.
    print(f"Iter {i}: Loss {loss.item():.4f}")

    # Disable gradients for quick evaluation snippets.
    with torch.no_grad():
        # Compute middle row index (placeholder for optional quick diagr
        row_idx = test_H // 2

# Print final render start message.
print("Rendering Final Result...")
# Set model to evaluation mode.
model.eval()
# Prepare list to collect rendered RGB chunks.
all_rgb = []
# Choose chunk size to avoid high memory usage when rendering all rays.
chunk = 1024
# Disable gradients during final inference rendering.
with torch.no_grad():
    # Iterate over all rays in chunks.
    for j in range(0, test_rays_o.shape[0], chunk):
        # Slice chunk of ray origins.
        batch_rays_o = test_rays_o[j:j + chunk]
        # Slice chunk of ray directions.
        batch_rays_d = test_rays_d[j:j + chunk]
        # Render chunk RGB predictions.
        rgb, _ = render_rays(batch_rays_o, batch_rays_d, model, embedder, ne
        # Move chunk to CPU and append for concatenation.
        all_rgb.append(rgb.cpu())

# Concatenate all chunks and reshape back to image grid.
final_img = torch.cat(all_rgb, 0).reshape(test_H, test_W, 3)

# Create figure for side-by-side qualitative and quantitative results.
plt.figure(figsize=(10, 4))
# Plot target ground-truth image.
plt.subplot(1, 3, 1)
# Draw target image content.
plt.imshow(test_gt.cpu())
# Add title for target panel.

```

```

plt.title("Target")
# Plot learned NeRF rendering.
plt.subplot(1, 3, 2)
# Draw predicted final image.
plt.imshow(final_img)
# Add title for prediction panel.
plt.title("Learned NeRF")
# Plot loss curve over iterations.
plt.subplot(1, 3, 3)
# Draw training loss history values.
plt.plot(history_loss)
# Add title for loss panel.
plt.title("Loss")
# Render final figure.
plt.show()

```

Starting Training...

Iter 0: Loss 0.1401

Iter 100: Loss 0.0096

Iter 200: Loss 0.0067

Iter 300: Loss 0.0010

Iter 400: Loss 0.0007

Iter 500: Loss 0.0002

Iter 600: Loss 0.0001

Iter 700: Loss 0.0001


Iter 800: Loss 0.0001

Iter 900: Loss 0.0001

Iter 1000: Loss 0.0002

Rendering Final Result...

Clipping input data to the valid range for imshow with RGB data ([0..1] for floats or [0..255] for integers). Got range [0.0..1.0992501].






NeRF: Αναπαράσταση Σκηνών ως Νευρωνικά Πεδία Ακτινοβολίας για Σύνθεση Νέων Όψεων

Μια οπτική ανάλυση της πρωτοποριακής εργασίας των Mildenhall
et al., UC Berkeley & Google Research

Το ζητούμενο: Φωτορεαλιστικές νέες όψεις από ένα αραιό σύνολο εικόνων

Η σύνθεση νέων όψεων (view synthesis) είναι μια μακροχρόνια πρόκληση στην επιστήμη των υπολογιστών. Ο στόχος είναι η δημιουργία νέων, φωτορεαλιστικών εικόνων μιας τρισδιάστατης σκηνής, χρησιμοποιώντας ως είσοδο μόνο ένα περιορισμένο σύνολο φωτογραφιών με γνωστές θέσεις κάμερας.




Οι προηγούμενες μέθοδοι είχαν θεμελιώδεις περιορισμούς

Οι παραδοσιακές προσεγγίσεις βασίζονταν σε διακριτές αναπαραστάσεις της γεωμετρίας, καθεμία με τα δικά της μειονεκτήματα.



Πλέγματα (Meshes)

- Η βελτιστοποίηση μέσω gradient descent είναι συχνά δύσκολη λόγω τοπικών ελαχίστων.
- Απαιτούν συνήθως ένα αρχικό πλέγμα με σταθερή τοπολογία, κάτι που δεν είναι διαθέσιμο για μη ελεγχόμενες σκηνές του πραγματικού κόσμου.



Πλέγματα Voxel (Voxel Grids)

- Η ικανότητά τους να κλιμακωθούν σε υψηλότερες αναλύσεις περιορίζεται θεμελιωδώς από την κακή πολυπλοκότητα χρόνου και χώρου.
- Αντιμετωπίζουν απαγορευτικό κόστος αποθήκευσης για τη μοντελοποίηση σύνθετων σκηνών σε υψηλή ανάλυση.


Η νέα ιδέα: Αναπαριστώντας την πραγματικότητα ως μια συνεχή συνάρτηση

Το NeRF προτείνει μια ριζικά διαφορετική προσέγγιση: αντί να αναπαριστά τη γεωμετρία, μαθαίνει μια συνεχή 5D συνάρτηση που κωδικοποιεί ολόκληρη τη σκηνή. Αυτή η συνάρτηση F_{Θ} , που υλοποιείται από ένα απλό MLP, αντιστοιχίζει κάθε τρισδιάστατη θέση $\mathbf{x} = (x, y, z)$ και δισδιάστατη κατεύθυνση θέασης $\mathbf{d} = (\theta, \phi)$ σε μια τιμή χρώματος $\mathbf{c} = (r, g, b)$ και πυκνότητας όγκου σ .



Η διαδικασία από τις ακτίνες στα pixels είναι πλήρως διαφορίσιμη


Η απόδοση μιας εικόνας με το NeRF ακολουθεί τέσσερα βήματα. Επειδή ολόκληρη η διαδικασία είναι διαφορίσιμη, μπορούμε να βελτιστοποιήσουμε τα βάρη του δικτύου ελαχιστοποιώντας απλώς τη διαφορά μεταξύ των αποδοθέντων και των πραγματικών pixels.



Η αρχιτεκτονική του δικτύου διαχωρίζει τη γεωμετρία από την εμφάνιση


Η αρχιτεκτονική του MLP ενσωματώνει μια σημαντική σχεδιαστική απόφαση για να εξασφαλίσει τη συνέπεια της σκηνής από πολλαπλές οπτικές γωνίες.

- Η είσοδος θέσης $\mathbf{x}$ (x, y, z) περνά μέσα από 8 πλήρως συνδεδεμένα επίπεδα για να παράγει την πυκνότητα όγκου σ και ένα διάνυσμα χαρακτηριστικών 256 διαστάσεων. Η πυκνότητα σ εξαρτάται μόνο από τη θέση, ορίζοντας τη γεωμετρία της σκηνής.
- Το διάνυσμα χαρακτηριστικών συνενώνεται με την κατεύθυνση θέασης $\mathbf{d}$ και περνά μέσα από ένα τελευταίο επίπεδο για να παράγει το χρώμα **RGB**. Αυτό επιτρέπει στο χρώμα να μεταβάλλεται ανάλογα με την οπτική γωνία.



Η εξάρτηση από τη θέαση επιτρέπει την αναπαράσταση μη-Lambertian φαινομένων

Επειδή το χρώμα εξαρτάται τόσο από τη θέση όσο και από την κατεύθυνση θέασης, το NeRF μπορεί να αναπαραστήσει με ακρίβεια πολύπλοκα υλικά. Για παράδειγμα, μπορεί να αποτυπώσει τις μεταβαλλόμενες κατοπτρικές αντανάκλασεις (specularities) σε μια γυαλιστερή επιφάνεια καθώς η κάμερα κινείται.




Η κλασική ογκομετρική απόδοση μετατρέπει τα σημεία σε τελικά pixels

Για να αποδώσουμε το χρώμα μιας ακτίνας, χρησιμοποιούμε αρχές από την κλασική απόδοση όγκου. Το αναμενόμενο χρώμα $\mathbf{C}(\mathbf{r})$ της ακτίνας υπολογίζεται μέσω ενός ολοκληρώματος που αθροίζει το χρώμα $\mathbf{c}$ και την πυκνότητα σ όλων των **σημείων** κατά μήκος της.

Για την αριθμητική προσέγγιση αυτού του ολοκληρώματος, χρησιμοποιούμε **στρωματοποιημένη δειγματοληψία (stratified sampling)**. Αντί για σταθερά σημεία, χωρίζουμε την ακτίνα σε N τμήματα και επιλέγουμε ένα τυχαίο δείγμα από κάθε τμήμα. Αυτό επιτρέπει στο MLP να αξιολογείται συχνείς θέσεις κατά τη διάρκεια της βελτιστοποίησης.

Το τελικό χρώμα υπολογίζεται με έναν κανόνα **τετραγωνισμού** που είναι διαφορίσιμος και ανάγεται στην παραδοσιακή άλφα σύνθεση.



$$\hat{\mathbf{C}}(\mathbf{r}) = \sum T_i (1 - \exp(-\sigma_i \delta_i)) \mathbf{c}_i$$

Βελτίωση 1: Η κωδικοποίηση θέσης επιτρέπει την αναπαράσταση υψηλών συχνοτήτων

Τα βαθιά νευρωνικά δίκτυα έχουν μια προδιάθεση να μαθαίνουν συναρτήσεις χαμηλών συχνοτήτων. Αυτό έχει ως αποτέλεσμα οι απλές υλοποιήσεις NeRF να παράγουν υπερβολικά εξομαλυμένες εικόνες.

Η λύση είναι η **Κωδικοποίηση Θέσης (Positional Enc)**. Πριν περάσουν στο δίκτυο, οι συντεταγμένες εισόδου (x και d) αντιστοιχίζονται σε ένα χώρο υψηλότερης διάστασης χρησιμοποιώντας ένα σύνολο συναρτήσεων $\sin$ και $\cos$ υψηλής συχνότητας. Αυτό επιτρέπει στο MLP να μάθει με επιτυχία τις λεπτομέρειες υψηλής συχνότητας τόσο στη γεωμετρία όσο και στην υφή.



Πλήρες Μοντέλο




Χωρίς Κωδικοποίηση Θέσης

Βελτίωση 2: Η ιεραρχική δειγματοληψία εστιάζει την υπολογιστική ισχύ

Η πυκνή αξιολόγηση του δικτύου κατά μήκος κάθε ακτίνας είναι αναποτελεσματική, καθώς πολλά δείγματα πέφτουν σε κενό ή κρυμμένο χώρο. Το NeRF χρησιμοποιεί μια ιεραρχική στρατηγική δειγματοληψίας δύο σταδίων:

1. **Δίκτυο "Coarse"**: Αρχικά, λαμβάνουμε ένα σύνολο N_c δειγμάτων με στρωματοποιημένη δειγματοληψία και τα αξιολογούμε με ένα "χονδρικό" δίκτυο. Η έξοδος αυτού του δικτύου χρησιμοποιείται για να παραχθεί μια κατανομή πιθανότητας κατά μήκος της ακτίνας, η οποία υποδεικνύει πού είναι πιθανό να υπάρχει ορατό περιεχόμενο.
2. **Δίκτυο "Fine"**: Στη συνέχεια, λαμβάνουμε ένα δεύτερο, πιο πληροφορημένο σύνολο N_f δειγμάτων από αυτή την κατανομή. Ένα τελικό "λεπτομερές" δίκτυο αξιολογεί το σύνολο και των $N_c + N_f$ δειγμάτων για να παράγει το τελικό, υψηλής ποιότητας χρώμα της ακτίνας.



Το αποτέλεσμα: Φωτορεαλισμός που αναπαριστά με συνέπεια την παραμικρή λεπτομέρεια

Σε σύγκριση με προηγούμενες μεθόδους, το NeRF είναι σε θέση να αναπαραστήσει με συνέπεια πολύπλοκες γεωμετρίες και λεπτές υφές σε πολλαπλές απόψεις. Ανακατασκευάζει σωστά περιοχές που είναι μερικώς κρυμμένες και αποφεύγει τα τεχνουργήματα (artifacts) που εμφανίζονται σε άλλες μεθόδους.



Ground Truth



NeRF (ours)




LLFF



SRN

Οι μετρήσεις επιβεβαιώνουν την ανωτερότητα του NeRF σε πολλαπλά σύνολα δεδομένων

Το NeRF ξεπερνά ποσοτικά τις προηγούμενες κορυφαίες τεχνικές για τη σύνθεση όψεων, όπως τα Scene Representation Networks (SRN) και το Local Light Field Fusion (LLFF), σε ένα ευρύ φάσμα συνθετικών και πραγματικών σκηνών.



Κάθε στοιχείο είναι κρίσιμο για την επίτευξη υψηλής πιστότητας

Οι μελέτες αφαίρεσης (ablation studies) αποδεικνύουν την καθοριστική συμβολή κάθε καινοτομίας του NeRF. Η αφαίρεση της Κωδικοποίησης Θέσης ή της Εξάρτησης από τη Θέαση οδηγεί σε σημαντική μείωση της ποιότητας της απόδοσης.



1. Πλήρες Μοντέλο
PSNR: 31.01



2. Χωρίς Εξάρτηση από τη Θέαση
PSNR: 27.66




3. Χωρίς Κωδικοποίηση Θέσης
PSNR: 28.77

Ο πρακτικός συμβιβασμός: Χρόνος εκπαίδευσης έναντι αποθηκευτικού χώρου

Ο πρακτικός συμβιβασμός: Χρόνος εκπαίδευσης έναντι **να αποθηκευτικού** χώρου
Το NeRF προσφέρει έναν εξαιρετικά αποδοτικό τρόπο αναπαράστασης σκηνών, αλλά απαιτεί σημαντικό χρόνο βελτιστοποίησης για κάθε σκηνή.

Αποθηκευτικός Χώρος (Ανά Σκηνή)



Σχετική συμπίεση **3000x**

Χρόνος Εκπαίδευσης (Ανά Σκηνή)



LLFF: <10 λεπτά



NeRF: 1-2 ημέρες σε μία GPU NVIDIA V100

Προς μια νέα εποχή γραφικών που βασίζονται σε πραγματικές εικόνες

Το NeRF αντιμετώπισε τις ελλείψεις των προηγούμενων μεθόδων αποδεικνύοντας ότι η αναπαράσταση σκηνών ως συνεχών 5D νευρωνικών πεδίων ακτινοβολίας μπορεί να παράγει φωτορεαλιστικά αποτελέσματα που ξεπερνούν κατά πολύ τις προσεγγίσεις που βασίζονται σε διακριτές αναπαραστάσεις.

Βασικές Συνεισφορές

- Αναπαράσταση συνεχών σκηνών ως 5D NeRFs, παραμετροποιημένων από ένα MLP.
- Διαφορίσιμη διαδικασία απόδοσης όγκου με ιεραρχική δειγματοληψία.
- Χρήση κωδικοποίησης θέσης για την αποτύπωση λεπτομερειών υψηλής συχνότητας.

Μελλοντικός Αντίκτυπος

Αυτή η εργασία ανοίγει τον δρόμο για ένα pipeline γραφικών όπου σύνθετες σκηνές θα μπορούσαν να συντεθούν από νευρωνικά πεδία ακτινοβολίας βελτιστοποιημένα απευθείας από εικόνες του πραγματικού κόσμου.

