




NeRF: Αναπαράσταση Σκηνών ως Νευρωνικά Πεδία Ακτινοβολίας για Σύνθεση Νέων Όψεων

Μια οπτική ανάλυση της πρωτοποριακής εργασίας των Mildenhall
et al., UC Berkeley & Google Research

Το ζητούμενο: Φωτορεαλιστικές νέες όψεις από ένα αραιό σύνολο εικόνων

Η σύνθεση νέων όψεων (view synthesis) είναι μια μακροχρόνια πρόκληση στην επιστήμη των υπολογιστών. Ο στόχος είναι η δημιουργία νέων, φωτορεαλιστικών εικόνων μιας τρισδιάστατης σκηνής, χρησιμοποιώντας ως είσοδο μόνο ένα περιορισμένο σύνολο φωτογραφιών με γνωστές θέσεις κάμερας.




Οι προηγούμενες μέθοδοι είχαν θεμελιώδεις περιορισμούς

Οι παραδοσιακές προσεγγίσεις βασίζονταν σε διακριτές αναπαραστάσεις της γεωμετρίας, καθεμία με τα δικά της μειονεκτήματα.



Πλέγματα (Meshes)

- Η βελτιστοποίηση μέσω gradient descent είναι συχνά δύσκολη λόγω τοπικών ελαχίστων.
- Απαιτούν συνήθως ένα αρχικό πλέγμα με σταθερή τοπολογία, κάτι που δεν είναι διαθέσιμο για μη ελεγχόμενες σκηνές του πραγματικού κόσμου.




Πλέγματα Voxel (Voxel Grids)

- Η ικανότητά τους να κλιμακωθούν σε υψηλότερες αναλύσεις περιορίζεται θεμελιωδώς από την κακή πολυπλοκότητα χρόνου και χώρου.
- Αντιμετωπίζουν απαγορευτικό κόστος αποθήκευσης για τη μοντελοποίηση σύνθετων σκηνών σε υψηλή ανάλυση.


Η νέα ιδέα: Αναπαριστώντας την πραγματικότητα ως μια συνεχή συνάρτηση

Το NeRF προτείνει μια ριζικά διαφορετική προσέγγιση: αντί να αναπαριστά τη γεωμετρία, μαθαίνει μια συνεχή 5D συνάρτηση που κωδικοποιεί ολόκληρη τη σκηνή. Αυτή η συνάρτηση F_{Θ} , που υλοποιείται από ένα απλό MLP, αντιστοιχίζει κάθε τρισδιάστατη θέση $\mathbf{x} = (x, y, z)$ και δισδιάστατη κατεύθυνση θέασης $\mathbf{d} = (\theta, \phi)$ σε μια τιμή χρώματος $\mathbf{c} = (r, g, b)$ και πυκνότητας όγκου σ .



Η διαδικασία από τις ακτίνες στα pixels είναι πλήρως διαφορίσιμη


Η απόδοση μιας εικόνας με το NeRF ακολουθεί τέσσερα βήματα. Επειδή ολόκληρη η διαδικασία είναι διαφορίσιμη, μπορούμε να βελτιστοποιήσουμε τα βάρη του δικτύου ελαχιστοποιώντας απλώς τη διαφορά μεταξύ των αποδοθέντων και των πραγματικών pixels.



Η αρχιτεκτονική του δικτύου διαχωρίζει τη γεωμετρία από την εμφάνιση


Η αρχιτεκτονική του MLP ενσωματώνει μια σημαντική σχεδιαστική απόφαση για να εξασφαλίσει τη συνέπεια της σκηνής από πολλαπλές οπτικές γωνίες.

- Η είσοδος θέσης $\mathbf{x}$ (x, y, z) περνά μέσα από 8 πλήρως συνδεδεμένα επίπεδα για να παράγει την πυκνότητα όγκου σ και ένα διάνυσμα χαρακτηριστικών 256 διαστάσεων. Η πυκνότητα σ εξαρτάται μόνο από τη θέση, ορίζοντας τη γεωμετρία της σκηνής.
- Το διάνυσμα χαρακτηριστικών συνενώνεται με την κατεύθυνση θέασης $\mathbf{d}$ και περνά μέσα από ένα τελευταίο επίπεδο για να παράγει το χρώμα **RGB**. Αυτό επιτρέπει στο χρώμα να μεταβάλλεται ανάλογα με την οπτική γωνία.





Η εξάρτηση από τη θέαση επιτρέπει την αναπαράσταση μη-Lambertian φαινομένων

Επειδή το χρώμα εξαρτάται τόσο από τη θέση όσο και από την κατεύθυνση θέασης, το NeRF μπορεί να αναπαραστήσει με ακρίβεια πολύπλοκα υλικά. Για παράδειγμα, μπορεί να αποτυπώσει τις μεταβαλλόμενες κατοπτρικές αντανακλάσεις (specularities) σε μια γυαλιστερή επιφάνεια καθώς η κάμερα κινείται.



Σημείο στο πλοίο:
Σχετικά σταθερό χρώμα




Σημείο στο νερό:
Μεταβαλλόμενη
κατοπτρική
αντανάκλαση (specularity)

Η κλασική ογκομετρική απόδοση μετατρέπει τα σημεία σε τελικά pixels

Για να αποδώσουμε το χρώμα μιας ακτίνας, χρησιμοποιούμε αρχές από την κλασική απόδοση όγκου. Το αναμενόμενο χρώμα $\mathbf{C}(\mathbf{r})$ της ακτίνας υπολογίζεται μέσω ενός ολοκληρώματος που αθροίζει το χρώμα $\mathbf{c}$ και την πυκνότητα σ όλων των **σημείων** κατά μήκος της.

Για την αριθμητική προσέγγιση αυτού του ολοκληρώματος, χρησιμοποιούμε **στρωματοποιημένη δειγματοληψία (stratified sampling)**. Αντί για σταθερά σημεία, χωρίζουμε την ακτίνα σε N τμήματα και επιλέγουμε ένα τυχαίο δείγμα από κάθε τμήμα. Αυτό επιτρέπει στο MLP να αξιολογείται συχνείς θέσεις κατά τη διάρκεια της βελτιστοποίησης.

Το τελικό χρώμα υπολογίζεται με έναν κανόνα **τετραγωνισμού** που είναι διαφορίσιμος και ανάγεται στην παραδοσιακή άλφα σύνθεση.



$$\hat{C}(\mathbf{r}) = \sum T_i (1 - \exp(-\sigma_i \delta_i)) c_i$$

Βελτίωση 1: Η κωδικοποίηση θέσης επιτρέπει την αναπαράσταση υψηλών συχνοτήτων

Τα βαθιά νευρωνικά δίκτυα έχουν μια προδιάθεση να μαθαίνουν συναρτήσεις χαμηλών συχνοτήτων. Αυτό έχει ως αποτέλεσμα οι απλές υλοποιήσεις NeRF να παράγουν υπερβολικά εξομαλυμένες εικόνες.

Η λύση είναι η **Κωδικοποίηση Θέσης (Positional Enc)**. Πριν περάσουν στο δίκτυο, οι συντεταγμένες εισόδου (x και d) αντιστοιχίζονται σε ένα χώρο υψηλότερης διάστασης χρησιμοποιώντας ένα σύνολο συναρτήσεων $\sin$ και $\cos$ υψηλής συχνότητας. Αυτό επιτρέπει στο MLP να μάθει με επιτυχία τις λεπτομέρειες υψηλής συχνότητας τόσο στη γεωμετρία όσο και στην υφή.



Πλήρες Μοντέλο




Χωρίς Κωδικοποίηση Θέσης

Βελτίωση 2: Η ιεραρχική δειγματοληψία εστιάζει την υπολογιστική ισχύ

Η πυκνή αξιολόγηση του δικτύου κατά μήκος κάθε ακτίνας είναι αναποτελεσματική, καθώς πολλά δείγματα πέφτουν σε κενό ή κρυμμένο χώρο. Το NeRF χρησιμοποιεί μια ιεραρχική στρατηγική δειγματοληψίας δύο σταδίων:

1. **Δίκτυο "Coarse"**: Αρχικά, λαμβάνουμε ένα σύνολο N_c δειγμάτων με στρωματοποιημένη δειγματοληψία και τα αξιολογούμε με ένα "χονδρικό" δίκτυο. Η έξοδος αυτού του δικτύου χρησιμοποιείται για να παραχθεί μια κατανομή πιθανότητας κατά μήκος της ακτίνας, η οποία υποδεικνύει πού είναι πιθανό να υπάρχει ορατό περιεχόμενο.
2. **Δίκτυο "Fine"**: Στη συνέχεια, λαμβάνουμε ένα δεύτερο, πιο πληροφορημένο σύνολο N_f δειγμάτων από αυτή την κατανομή. Ένα τελικό "λεπτομερές" δίκτυο αξιολογεί το σύνολο και των $N_c + N_f$ δειγμάτων για να παράγει το τελικό, υψηλής ποιότητας χρώμα της ακτίνας.



Το αποτέλεσμα: Φωτορεαλισμός που αναπαριστά με συνέπεια την παραμικρή λεπτομέρεια

Σε σύγκριση με προηγούμενες μεθόδους, το NeRF είναι σε θέση να αναπαραστήσει με συνέπεια πολύπλοκες γεωμετρίες και λεπτές υφές σε πολλαπλές απόψεις. Ανακατασκευάζει σωστά περιοχές που είναι μερικώς κρυμμένες και αποφεύγει τα τεχνουργήματα (artifacts) που εμφανίζονται σε άλλες μεθόδους.



Ground Truth



NeRF (ours)




LLFF



SRN

Οι μετρήσεις επιβεβαιώνουν την ανωτερότητα του NeRF σε πολλαπλά σύνολα δεδομένων

Το NeRF ξεπερνά ποσοτικά τις προηγούμενες κορυφαίες τεχνικές για τη σύνθεση όψεων, όπως τα Scene Representation Networks (SRN) και το Local Light Field Fusion (LLFF), σε ένα ευρύ φάσμα συνθετικών και πραγματικών σκηνών.



Κάθε στοιχείο είναι κρίσιμο για την επίτευξη υψηλής πιστότητας

Οι μελέτες αφαίρεσης (ablation studies) αποδεικνύουν την καθοριστική συμβολή κάθε καινοτομίας του NeRF. Η αφαίρεση της Κωδικοποίησης Θέσης ή της Εξάρτησης από τη Θέαση οδηγεί σε σημαντική μείωση της ποιότητας της απόδοσης.



1. Πλήρες Μοντέλο
PSNR: 31.01



2. Χωρίς Εξάρτηση από τη Θέαση
PSNR: 27.66




3. Χωρίς Κωδικοποίηση Θέσης
PSNR: 28.77

Ο πρακτικός συμβιβασμός: Χρόνος εκπαίδευσης έναντι αποθηκευτικού χώρου

Ο πρακτικός συμβιβασμός: Χρόνος εκπαίδευσης έναντι **να αποθηκευτικού** χώρου
Το NeRF προσφέρει έναν εξαιρετικά αποδοτικό τρόπο αναπαράστασης σκηνών, αλλά απαιτεί σημαντικό χρόνο βελτιστοποίησης για κάθε σκηνή.

Αποθηκευτικός Χώρος (Ανά Σκηνή)



Σχετική συμπίεση **3000x**

Χρόνος Εκπαίδευσης (Ανά Σκηνή)



LLFF: <10 λεπτά



NeRF: 1-2 ημέρες σε μία GPU NVIDIA V100

Προς μια νέα εποχή γραφικών που βασίζονται σε πραγματικές εικόνες

Το NeRF αντιμετώπισε τις ελλείψεις των προηγούμενων μεθόδων αποδεικνύοντας ότι η αναπαράσταση σκηνών ως συνεχών 5D νευρωνικών πεδίων ακτινοβολίας μπορεί να παράγει φωτορεαλιστικά αποτελέσματα που ξεπερνούν κατά πολύ τις προσεγγίσεις που βασίζονται σε διακριτές αναπαραστάσεις.

Βασικές Συνεισφορές

- Αναπαράσταση συνεχών σκηνών ως 5D NeRFs, παραμετροποιημένων από ένα MLP.
- Διαφορίσιμη διαδικασία απόδοσης όγκου με ιεραρχική δειγματοληψία.
- Χρήση κωδικοποίησης θέσης για την αποτύπωση λεπτομερειών υψηλής συχνότητας.

Μελλοντικός Αντίκτυπος

Αυτή η εργασία ανοίγει τον δρόμο για ένα pipeline γραφικών όπου σύνθετες σκηνές θα μπορούσαν να συντεθούν από νευρωνικά πεδία ακτινοβολίας βελτιστοποιημένα απευθείας από εικόνες του πραγματικού κόσμου.

